Meme Kanseri Teşhisinde Makine Öğrenmesi Modellerinin Karşılaştırmalı Analizi

Öğrenci Adı Soyadı : SEMA HACIBEKİROĞLU

Öğrenci Numarası : 427635

GİTHUB Linki :
https://github.com/semaHbo/Derin_Ogrenme_Odev/tree/main/Makine_ogrenmesi_yontemleriyle_siniflandirma

Makine Öğrenmesi Yöntemleriyle Meme Kanseri Sınıflandırması

1. Giriş ve Problem Tanımı

Bu çalışmanın temel amacı, Wisconsin Meme Kanseri (Breast Cancer Wisconsin) veri setini kullanarak, hücre çekirdeğinden elde edilen dijital görüntü özelliklerine dayalı bir sınıflandırma modeli geliştirmektir. Problem, tümörlerin **iyi huylu (benign)** veya **kötü huylu (malignant)** olarak sınıflandırılmasıdır ve doğası gereği bir **ikili sınıflandırma (binary classification)** problemidir.

Projenin temel motivasyonu, tıbbi teşhis alanında makine öğrenmesinin gücünü göstermek ve farklı algoritmaların bu alandaki performansını karşılaştırmaktır. Tıbbi teşhis bağlamında, bir modelin **yanlış negatif (False Negative)** oranı, yani gerçekte kanserli bir hastaya "sağlıklı" deme olasılığı, hayati önem taşır. Bu nedenle, çalışma boyunca modellerin performansı yalnızca genel doğruluk (Accuracy) ile değil, özellikle duyarlılık (Recall), kesinlik (Precision) ve F1-Skoru metrikleriyle de detaylıca incelenmiştir.

---

2. Veri Seti ve Ön İşleme (Dataset & Preprocessing)

Çalışmada kullanılan veri seti, literatürde yaygın olarak kullanılan **Breast Cancer Wisconsin (Diagnostic) Dataset**'idir. Veri seti, 569 örnek ve 32 sütundan oluşmaktadır. Bu sütunların 30'u, hücre çekirdeğinin aşağıdaki özelliklerine ait ortalama (mean), standart hata (se) ve en kötü (worst) değerleri olmak üzere hesaplanmış 10 temel özellikten türetilmiştir:

- Yarıçap (Radius)
- Doku (Texture)
- Çevre (Perimeter)
- Alan (Area)
- Düzgünlük (Smoothness)
- Kompaktlık (Compactness)
- İçbükeylik (Concavity)
- İçbükey Noktalar (Concave points)
- Simetri (Symmetry)
- Fraktal Boyut (Fractal Dimension)

Kalan iki sütun ise hasta kimlik numarası (id) ve hedef değişken olan tanı (diagnosis) sütunlarıdır. Projenin ilk aşaması olan veri ön işleme adımları şu şekilde gerçekleştirilmiştir:

- **Veri Temizliği:** Modelin öğrenme sürecini yanıltmaması için analitik bir değeri olmayan id sütunu ve tamamı boş değerlerden oluşan Unnamed: 32 sütunu veri setinden çıkarılmıştır.

- **Etiket Kodlaması (Label Encoding):** Kategorik hedef değişken olan diagnosis, makine öğrenmesi algoritmalarının işleyebilmesi için sayısal formata dönüştürülmüştür (Malignant: 1, Benign: 0). Bu işlem sonrası sınıfların dengeli olduğu gözlemlenmiştir (357 Benign, 212 Malignant).
- **Veri Bölümleme:** Modelin genelleme yeteneğini ölçmek ve eğitim sırasında görmediği veriler üzerinde test edilmesini sağlamak amacıyla veri seti, train_test_split fonksiyonu kullanılarak **%80 eğitim** ve **%20 test** olacak şekilde bölünmüştür. Sınıf dağılımının her iki sette de korunması için stratify parametresi kullanılmıştır.
- **Özellik Ölçeklendirme (Feature Scaling):** Veri setinde "Alan" gibi büyük değerlere sahip özelliklerin, "Düzgünlük" gibi küçük değerlere sahip özellikleri baskılamasını engellemek ve özellikle SVM gibi mesafe tabanlı algoritmaların performansını artırmak için **StandardScaler** kullanılmıştır. Bu işlemle tüm özellikler, ortalaması 0 ve standart sapması 1 olacak şekilde yeniden ölçeklendirilmiştir.

[AÇIKLAMA 1: Mühendislik Yaklaşımına Vurgu]
Tüm bu ön işleme adımları ve modelleme süreci, yazılım mühendisliğinin **SOLID prensipleri** ve modülerlik anlayışına uygun olarak tasarlanmıştır. Veri yükleme, ön işleme, model tanımları ve eğitim süreçleri ayrı Python dosyaları ve Jupyter not defterlerinde (classification.ipynb, train_models.ipynb) gerçekleştirilmiş, sonuçlar ise düzenli bir results/ klasöründe toplanmıştır. Bu yaklaşım, projenin sürdürülebilirliğini, tekrarlanabilirliğini ve genişletilebilirliğini artırmıştır.

---

3. Yöntem: Kullanılan Modeller ve Seçim Gerekçeleri

Bu çalışmada kullanılan üç farklı model, veri setindeki gizli örüntüleri (patterns) en iyi hangi matematiksel yaklaşımın yakalayacağını bulmak amacıyla **"farklı paradigmaları test etme" (spot-checking)** stratejisiyle seçilmiştir.

- **Lojistik Regresyon (LR) - *Doğrusal ve Olasılıksal Yaklaşım*:**
  İkili sınıflandırma problemlerinin temel ve en yaygın kullanılan algoritması olan Lojistik Regresyon, bu çalışmanın **referans (baseline) modeli** olarak belirlenmiştir. Amacı, 30 farklı hücre özelliğinin kanser olma olasılığına olan doğrusal etkisini modellemek ve sonuçları tıbbi bir vakada en anlaşılır (interpretable) şekilde, olasılık hesabı üzerinden yorumlayabilmektir. Diğer modellerin başarısı, bu basit ve güçlü referans modelin üzerindeki performanslarıyla değerlendirilecektir.
- **Rastgele Orman (Random Forest - RF) - *Ağaç Tabanlı Topluluk Yaklaşımı*:**
  Tıbbi veriler genellikle doğrusal olmayan (non-linear) ve karmaşık ilişkiler barındırır. Lojistik Regresyon'un yakalayamayacağı bu tür ilişkileri modelleyebilmek için ağaç tabanlı bir **topluluk (ensemble)** öğrenme yöntemi olan Random Forest tercih edilmiştir. Birden fazla karar ağacının bir araya gelerek oylama yapması, modelin

eğitim verisini ezberlemesini (overfitting) önlerken, tıbbi teşhiste hangi özelliklerin (feature importance) daha kritik olduğunu belirleme açısından da değerli bilgiler sunar.

- **Destek Vektör Makineleri (SVM) - *Geometrik ve Marj Optimizasyonu Yaklaşımı*:** Veri setimiz 30 farklı boyuta (özelliğe) sahiptir. SVM, yüksek boyutlu uzaylarda sınıflar (iyi huylu ve kötü huylu) arasına maksimum aralıklı (maximum margin) bir karar sınırı (hiperdüzlem) çizme konusunda matematiksel olarak en güçlü algoritmalardan biridir. Veri setimiz StandardScaler ile başarıyla ölçeklendirildiği için, SVM'in bu metrik uzayda iki sınıfı birbirinden en net sınırlarla ayırması ve özellikle yanlış sınıflandırma riskini en aza indirmesi hedeflenmiştir.

---

4. Deneysel Sonuçlar ve Model Performanslarının Karşılaştırmalı Analizi

Modeller eğitildikten sonra, test seti üzerinde elde edilen performans metrikleri aşağıdaki tabloda özetlenmiştir:

Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.9649	0.9750	0.9286	0.9512
Random Forest	0.9649	**1.0000**	0.9048	0.9500
SVM	**0.9737**	**1.0000**	**0.9286**	**0.9630**

[AÇIKLAMA 2: Sonuçların Derinlemesine Yorumu]

Sonuçlar incelendiğinde, tüm modellerin oldukça başarılı olduğu görülmektedir. Ancak detaylı bir analiz, modeller arasındaki ince farkları ortaya koymaktadır:

- **Genel Performans: SVM modeli**, 0.9737'lik doğruluk (Accuracy) ve 0.9630'lık F1-Skoru ile en yüksek genel performansı göstermiştir. Bu, SVM'in yüksek boyutlu bu veri setinde sınıflar arasındaki ayrımı en iyi şekilde gerçekleştirdiğini kanıtlamaktadır.
- **Tıbbi Teşhis Bağlamında Değerlendirme:**
    - **Precision (Kesinlik):** Random Forest ve SVM modelleri, **1.0000**'lık mükemmel Precision skoruyla kanser teşhisi koydukları **(pozitif olarak tahmin ettikleri)** hiçbir vakada yanılmamışlardır. Bu, her iki modelin de **sıfır yanlış pozitif (False Positive)** ürettiği anlamına gelir; yani sağlıklı bir hastaya yanlışlıkla kanser teşhisi koymamışlardır. Bu durum, gereksiz tedavi ve hasta psikolojisi açısından son derece önemlidir.
    - **Recall (Duyarlılık):** Random Forest modelinin Recall değeri 0.9048'de kalarak, gerçekte kanserli olan bazı hastaları (yaklaşık %10) gözden

kaçırdığını **(yüksek yanlış negatif)** göstermektedir. Bu, bir tarama testi için kabul edilemez bir durumdur.

  - **En İyi Denge:** SVM modeli ise mükemmel kesinliğini (Precision=1.0), en yüksek ikinci duyarlılık değeriyle (Recall=0.9286) birleştirerek, **yanlış negatif oranını minimize ederken yanlış pozitif oranını sıfırlayan** en güvenilir teşhis aracı olduğunu kanıtlamıştır. Bu, onu bu veri seti için en dengeli ve etkili model yapmaktadır.

- **Model Karşılaştırması:**
  - **Lojistik Regresyon**, basit yapısına rağmen 0.9649 doğruluk ile oldukça başarılı bir **referans model** görevi görmüştür.
  - **Random Forest**'ın, Lojistik Regresyon'a göre daha düşük Recall üretmesi, ağaç tabanlı yapısının bu özel veri setinde tüm kanserli vakaları yakalamakta biraz daha "katı" veya "güvenli" bir karar sınırı çizdiğini, bu nedenle bazı zor vakaları gözden kaçırdığını düşündürebilir.

---

5. Sonuç ve Çıktıların Yönetimi

Bu çalışma, meme kanseri teşhisinde makine öğrenmesi modellerinin başarıyla uygulanabileceğini göstermiştir. Yapılan karşılaştırmalı analiz sonucunda, **SVM algoritması**, hem yüksek doğruluk hem de tıbbi açıdan kritik öneme sahip olan Precision ve Recall metrikleri arasında kurduğu en iyi denge sayesinde bu veri seti için en başarılı model olarak belirlenmiştir.

[AÇIKLAMA 3: Çıktı Yönetimi ve Sürdürülebilirlik]
Mühendislik yaklaşımının bir gereği olarak, tüm deneysel sonuçlar sistematik bir şekilde yönetilmiştir:

- Her bir modelin test seti üzerindeki tahminleri (y_pred), gerçek değerler (y_true) ile birlikte results/ klasörüne ayrı CSV dosyaları olarak kaydedilmiştir (logistic_regression_results.csv, random_forest_results.csv, svm_results.csv).
- Tüm modellere ait performans metrikleri (Accuracy, Precision, Recall, F1-Score) tek bir CSV dosyasında (models_metrics.csv) toplanarak karşılaştırmalı analiz kolaylaştırılmıştır.
- Eğitilmiş en iyi modellerin ağırlıkları, gelecekte tekrar eğitime gerek kalmadan kullanılmak veya bir API'ye entegre edilmek üzere Python'un joblib kütüphanesi kullanılarak .pkl formatında (logistic_regression_model.pkl, random_forest_model.pkl, svm_model.pkl) dışa aktarılmıştır.
- Veri kaybını önlemek ve çalışmanın bütünlüğünü korumak adına tüm results/ klasörü, Google Drive ortamına yedeklenmiştir.