

YAPAY SİNİR AĞLARI İLE XOR PROBLEMİNİN ÇÖZÜLMESİ

Öğrenci Adı Soyadı : SEMA HACİBEKİROĞLU

Öğrenci Numarası : 427635

Github Linki :

https://github.com/semaHbo/Derin_Ogrenme_Odev/tree/main/XOR_Egitimi

1. Giriş

Makine öğrenmesi modellerinin başarısı büyük ölçüde verideki karmaşık ilişkileri öğrenebilme yeteneğine bağlıdır. Doğrusal modeller yalnızca doğrusal olarak ayrılabilir veri kümelerinde başarılı olurken, gerçek dünyadaki birçok problem doğrusal olmayan ilişkiler içermektedir.

Bu durumu açıklamak için literatürde sıklıkla kullanılan örneklerden biri **XOR problem** problemidir.

XOR problemi, iki giriş değişkeninin birbirine eşit olup olmamasına göre çıktı üreten basit bir mantıksal işlemdir. Ancak bu veri yapısı doğrusal olarak ayrılabilir değildir. Bu nedenle **Perceptron** gibi tek katmanlı modeller bu problemi çözememektedir.

Bu sınırlılık, çok katmanlı yapay sinir ağlarının geliştirilmesinde önemli rol oynamıştır. Gizli katman içeren modeller doğrusal olmayan dönüşümler öğrenerek karmaşık veri yapılarını temsil edebilmektedir.

Bu çalışmanın amacı, XOR probleminin:

- tek katmanlı model ile çözülemeyeceğini göstermek
- çok katmanlı sinir ağlarının bu problemi nasıl öğrendiğini incelemek
- farklı hiperparametre kombinasyonlarının model performansına etkisini analiz etmektir.

2. Veri Seti

Bu çalışmada kullanılan veri seti XOR fonksiyonuna ait dört örnekten oluşmaktadır.

x1 x2 y


0 0 0

0 1 1

1 0 1

1 1 0

Bu veri seti iki boyutlu uzayda aşağıdaki gibi konumlanmaktadır.



Bu grafikte görüldüğü gibi aynı sınıfa ait noktalar karşılıklı köşelerde yer almaktadır. Bu durum verinin tek bir doğru ile ayrılmasını imkânsız hale getirmektedir.

3. Mühendislik Yaklaşımı

Bu çalışmada problem mühendislik bakış açısıyla sistematik bir şekilde ele alınmıştır.

Problem Tanımı

XOR veri seti doğrusal olarak ayrılabilir değildir. Bu nedenle doğrusal karar sınırına sahip modeller veri setini doğru şekilde sınıflandıramaz.

Hipotez

Gizli katman içeren bir yapay sinir ağı modeli XOR problemini öğrenebilir.

Deney Tasarımı

Bu hipotezi test etmek için aşağıdaki deneyler yapılmıştır:

1. Tek katmanlı model kurulmuştur
2. Gizli katman eklenerek çok katmanlı model oluşturulmuştur
3. Eğitim süreci analiz edilmiştir
4. Gizli katman çıktıları incelenmiştir
5. Farklı hiperparametre kombinasyonları grid search yöntemi ile test edilmiştir

Bu yaklaşım sayesinde model davranışı sistematik olarak analiz edilmiştir.

4. Model Mimarisi

XOR problemini çözmek için **Multilayer Perceptron** mimarisi kullanılmıştır.

Model yapısı aşağıdaki gibidir:

- Giriş katmanı: 2 nöron
- Gizli katman: 2–8 nöron
- Çıkış katmanı: 1 nöron


Çıkış katmanında **Sigmoid function** kullanılmıştır. Bunun nedeni problemin ikili sınıflandırma olmasıdır.

Model eğitimi sırasında kayıp fonksiyonu olarak **Binary Crossentropy** kullanılmıştır. Bu kayıp fonksiyonu ikili sınıflandırma problemleri için en yaygın kullanılan fonksiyonlardan biridir.

Optimizasyon işlemi için **Adam optimizer** tercih edilmiştir. Adam optimizasyon algoritması öğrenme oranını adaptif olarak ayarlayarak eğitim sürecinin daha hızlı ve kararlı olmasını sağlar.

5. Eğitim Süreci Analizi

Model eğitimi sırasında kayıp fonksiyonunun epoch boyunca nasıl değiştiği incelenmiştir.




Grafikte görüldüğü gibi eğitim sürecinde kayıp değeri zamanla azalmaktadır. Bu durum modelin XOR ilişkisini öğrenmeye başladığını göstermektedir.

Epoch sayısının artırılması modelin daha iyi bir çözüm bulmasına yardımcı olmuştur.

6. Gizli Katman Temsili

Sinir ağlarının en önemli özelliklerinden biri veriyi yeni bir özellik uzayına dönüştürebilmeleridir. Bu nedenle modelin gizli katman çıktıları analiz edilmiştir.




Bu grafikte her veri noktasının gizli katmandaki temsili gösterilmektedir. Görüldüğü gibi gizli katman veriyi farklı bir uzaya dönüştürerek sınıfların daha kolay ayrılmasını sağlamaktadır.

Bu durum sinir ağlarının doğrusal olmayan veri ilişkilerini öğrenebilmesinin temel mekanizmasını göstermektedir.

7. Karar Sınırı Analizi

Modelin öğrendiği karar sınırı da incelenmiştir.



Bu grafikte modelin giriş uzayını nasıl böldüğü görülmektedir. Karar sınırının doğrusal olmadığı ve veri noktalarını doğru şekilde ayırdığı gözlemlenmektedir.

8. Hiperparametre Deneyleri

Model performansını daha iyi anlamak için farklı hiperparametre kombinasyonları denenmiştir.

Denenen parametreler:

- Hidden neuron sayısı
- Aktivasyon fonksiyonu
- Optimizer türü
- Epoch sayısı

Bu parametrelerin farklı kombinasyonları **grid search** yöntemi ile test edilmiştir.

Toplam:

90 farklı model eğitilmiştir.

	neurons	epochs	activation	optimizer	accuracy
8	2	3000	tanh	adam	1.0
66	5	5000	relu	adam	1.0
73	8	1000	relu	sgd	1.0
72	8	1000	relu	adam	1.0
85	8	5000	relu	sgd	1.0
81	8	3000	tanh	sgd	1.0
78	8	3000	relu	adam	1.0
50	4	5000	tanh	adam	1.0
55	5	1000	relu	sgd	1.0
56	5	1000	tanh	adam	1.0

Deney sonuçlarına göre birçok model %100 doğruluk elde etmiştir. Bu durum XOR probleminin küçük bir MLP modeli tarafından kolaylıkla öğrenilebildiğini göstermektedir.

En basit başarılı model aşağıdaki parametrelere sahiptir:

Parametre	Değer
Hidden neurons	2

Parametre	Değer
Activation	tanh
Optimizer	Adam
Epoch	3000

9. Sonuç

Bu çalışmada XOR probleminin yapay sinir ağları kullanılarak nasıl çözülebileceği incelenmiştir. Tek katmanlı perceptron modellerinin doğrusal karar sınırları nedeniyle bu problemi çözemediği gösterilmiştir.

Gizli katman içeren çok katmanlı sinir ağlarının ise doğrusal olmayan dönüşümler öğrenerek XOR veri setini başarıyla sınıflandırabildiği gözlemlenmiştir.

Grid search deneyleri sonucunda birçok hiperparametre kombinasyonunun yüksek doğruluk elde ettiği görülmüştür. En basit başarılı model yalnızca iki gizli nöron içermektedir.

Bu deney, derin öğrenme modellerinin karmaşık veri yapılarını öğrenebilme yeteneğini gösteren temel örneklerden biridir.